

REPVIT REPRODUCTION

RepViT 轻量图像分类模型 复现、优化与多模型部署

2026 秋 one 团队 AI 算法组考核 · 答辩汇报

RepViT: Revisiting Mobile CNN From ViT Perspective · CVPR 2024 · arXiv:2307.09283

github.com/8ga-tech/RepViT-Reproduction



78.20%

ImageNet 子集 Top-1

92.34%

Pet-37 test Top-1

7.1e-06

重参数化 $\max|\Delta \text{logits}|$

100%

PyTorch↔ONNX Top-1 一致

六个考核环节全部交付，37 条验收项自检 0 失败

运行 → 迁移 → 优化 → 可视化 → 重参数化 → 部署，每个数字都可在仓库中溯源

01

官方模型评价

5 个型号 · 1000 张子集

M0.9 Top-1 78.20%

outputs/pretrained_eval/

02

M0.9 迁移训练

Pet 37 类 · 40 epoch

test Top-1 92.34%

checkpoints/baseline_best.pt

03

控制变量优化

4 方案 + 3 组消融

7 份配置 DIFF PASS

configs/opt_*.yaml

04

可视化与可解释性

五曲线 · 混淆矩阵 · Grad-CAM

跨物种错误仅 3.56%

outputs/gradcam/

05

结构重参数化

BN 108 → 0 · Conv 126 → 103

max| Δ | 7.1e-06 · Top-1 32/32

outputs/reparam/

06

ONNX 多模型部署

6 个 ONNX · ORT CPU

P50 7.1 ~ 32.7 ms

onnx/*.onnx

M0.9 是 20 个 RepViT Block 的纯卷积流水线

形状由 forward hook 现测，非论文插图；分辨率 $224 \rightarrow 7$ ，通道 $3 \rightarrow 384$

输入

$224 \times 224 \times 3$ RGB

Stem

conv1 3×3 s2 $\rightarrow$ 24ch 112×112

conv2 3×3 s2 $\rightarrow$ 48ch 56×56

Stage 0

$2 \times$ RepViT Block 48ch 56×56

Stage 1

$2 \times$ RepViT Block 96ch 28×28

Stage 2

$14 \times$ RepViT Block 192ch 14×14

Block 数最多 —— 与论文「第三阶段布置更多 Block」一致

Stage 3

$2 \times$ RepViT Block 384ch 7×7

GAP $\rightarrow$ 384 维

Head RepViTClassifier (NormLinear) $\rightarrow$ 37 维

单个 RepViT Block

Token Mixer (空间混合)

$\text{RepVGGDW} = 3 \times 3 \text{ dw} + 1 \times 1 \text{ dw}$

Channel Mixer (通道混合)

1×1 升维 $\rightarrow$ GELU $\rightarrow 1 \times 1$ 降维

残差连接 + 部分 Block 带 SE

训练态 vs 推理态

训练态

3×3 dw 分支 + 1×1 dw 分支

两条分支各自带 BatchNorm

推理态

BN 折进卷积核后相加

$\rightarrow$ 单个 3×3 depthwise 卷积

名字里有 ViT，但结构里没有一个注意力算子

RepViT 借鉴的是轻量 ViT 的宏观架构选择，而非多头自注意力本身

标准 ViT	RepViT
空间混合 Multi-Head Self-Attention	RepVGGDW (3×3 dw + 1×1 dw)
通道混合 MLP / FFN	Channel Mixer (1×1 → GELU → 1×1)
下采样 patchify (stride=16 大核)	Early Conv Stem (两组 stride=2)
归纳偏置 弱，依赖大数据	强 (卷积自带局部性 / 平移等变)
ONNX 图内 MatMul + Softmax	无注意力算子
全部算术节点 Conv / Gemm / Add / Mul / Div / Clip / Relu 实证: onnx/*.onnx 的 op_histogram 与 outputs/reparam/*_onnx_nodes.json	

四个关键设计

分离 Token / Channel Mixer
空间与通道容量可独立调节

扩张比降到约 2，同时加宽
省下的 MACs 换成通道数

SE 不做每块都放
全局池化的延迟不可忽略

简单分类头
单个 BN + Linear，省真实延迟

M0.9 实测: 20 个 Block
[2, 2, 14, 2]

官方权重实测复现到 0.5 个点以内

1000 张自建分层子集（每类 1 张，种子 20260912）· 224×224 · batch 64 · FP32 · RTX 4060 Laptop

型号	参数量 (M)	MACs (G)	本机 Top-1	官方公布
RepViT-M0.9	5.489	0.847	78.20%	78.7%
RepViT-M1.0	7.303	1.143	79.90%	80.0%
RepViT-M1.1	8.803	1.358	79.90%	80.7%
RepViT-M1.5	14.644	2.308	82.80%	82.3%
RepViT-M2.3	23.689	4.574	83.10%	83.3%

预处理口径必须标

crop_pct = 0.875
Resize(256) + CenterCrop(224)

crop_pct = 0.95
Resize(235) + CenterCrop(224)

M0.9: 78.20 / 78.60
M1.0: 79.90 / 80.00

两套口径差 0.1~0.4 个点

必须声明的口径边界

本结果为「该自建验证子集上的实际运行结果」，不代表论文完整 ImageNet-1K 验证集结果。
子集为每类 1 张的分层抽样（1000 张），非考核方下发的指定子集；清单与哈希见 datasets/lists/imagenet_val_subset.txt
官方 iPhone 12 延迟 (0.9 / 1.0 ms) 与本机 CPU 结果不可横向比较

两套数据两套标签，三层划分零泄漏

37 类与 1000 类必须分别使用各自的标签文件；混用会让 Top-5 名称整体错乱

Oxford-IIIT Pet 划分（唯一划分脚本，seed=42）

trainval.txt 3680 行	pet_train.txt 2940 行 · 每类 73~80	pet_val.txt 740 行 · 每类恰好 20
test.txt 3669 行	pet_test.txt 3669 行 · 每类 88~100	test 只评价一次 eval_count = 1

官方 CLASS-ID 是 1-based, 0-based 标签 = CLASS-ID - 1；类名用 rsplit('_', 1) 取前缀

泄漏检查（三层 + 内容级）

文件名交集	0 / 0 / 0
MD5 交集（防改名）	0 / 0 / 0
孤儿图误入	0
划分内部重复图	0

python datasets/audit_leakage.py

官方数据事实基线（全部实测）

7390 images/ 下的 jpg	3680 trainval.txt 行数	3669 test.txt 行数	12 / 25 猫 / 狗 类别数	1-based 官方 CLASS-ID
---	--	--	---	---

官方不存在 train.txt / val.txt，只有 trainval.txt 与 test.txt；train/val 必须自行分层切分

40 epoch 迁移训练把 test Top-1 做到 92.34%

AdamW · cosine + 3ep warmup · Label Smoothing 0.1 · bf16 autocast · batch 64 · seed 42

测试集 (3669 张, 只评价一次)

92.34%

Top-1 Accuracy

99.26%

Top-5 Accuracy

92.22%

Macro-F1

验证集 (740 张) best 选模依据 val_macro_f1 = 0.9462 @ epoch 34

合规性自证

✓ 骨干确实被训练	706 张量
✓ 其中骨干张量	699 个
✓ test 只评价一次	eval_count=1
✓ 权重加载无异常	unexpected=0

1000 类 → 37 类: 怎么做、差异在哪

正确做法

```
timm.create_model(..., num_classes=37,  
distillation=False)
```

保留分类头的 BN 统计量 (与类别数无关的迁移先验)
missing = 2 (仅换头后的 Linear weight / bias)

禁止做法

```
model.reset_classifier(37)
```

会丢掉 head.head.bn 的统计量; distillation=False 时
head_dist 属性被整体删除, 后续断言必然失败

四组优化各有假设，控制变量由工具强制校验

Baseline 有两个问题：样本仅 2940 张而参数 473 万（过拟合风险）；主干前期被大学习率推离预训练解

B 混合增强

3 个差异键

Mixup $\alpha=0.2$ + CutMix $\alpha=1.0$ ，每个 batch 都做

假设：软标签平滑决策面，等价于训练集扩容

代价：需要更多 epoch 才能收敛

C 加强数据增强

8 个差异键

RandAugment($n=2, m=9$) + RRC scale 下限 $0.35 \rightarrow 0.25$

假设：覆盖旋转 / 剪切 / 色调变换，压缩纹理记忆

风险：2940 张下容易过增强

D 差异化学习率

1 个差异键

主干倍率 $0.1 \rightarrow 0.05$ （有效 lr $1e-4 \rightarrow 5e-5$ ）

假设：新头快速收敛，主干锚定在预训练解附近

代价：训练曲线整体右移

A 组合式（基础任务所选项）

12 个差异键

B + C + D 全开

假设：三者机制互补，前段更稳 + 末段更高

风险：正则叠加会延长收敛

控制变量不是靠自觉，而是可执行校验

```
python tools/diff_config.py configs/baseline.yaml configs/opt_combo.yaml
```

叶子级比对，实际差异键必须与配置声明的 `_expected_diff_` 逐项一致

7 份配置全部 DIFF PASS (3 / 8 / 1 / 12 / 8 / 1 / 9 键)

```
python tools/same_budget.py → total_iters_equal=True (8 组均为 40 epoch × 45 step)
```

保持不变

数据划分 · 预训练权重 · 种子

训练预算 · 评价方式 · 选模标准

8 组实验落在 0.6 个点的窄带内 —— 这是噪声，不是提升

诚实结论比「挑一个最好看的数」更有价值；题目明确允许优化结果不提升准确率

实验	差异键	val Macro-F1	test Top-1	test Macro-F1
baseline	—	0.9462	92.34%	92.22%
opt_mix (B)	3	0.9489	92.42%	92.27%
opt_randaug (C)	8	0.9450	92.18%	92.06%
opt_disc (D)	1	0.9421	92.20%	92.11%
opt_combo (A)	12	0.9489	92.12%	92.01%
opt_abl_a (=C)	8	0.9502	92.48%	92.36%
opt_abl_b (=D)	1	0.9433	92.53%	92.44%

为什么说是噪声

① 二项分布置信区间

3669 张、Top-1≈0.92 时

95% CI 半宽 ≈ ±0.9 个点

② 同配置重跑的波动

baseline 重跑一次

test 92.26 → 92.34

val F1 0.9502 → 0.9462

③ 无单调关系

三合一的 A 方案反而垫底

组合消融：A 抵消了 B 单独使用时的负作用

ΔA = +0.000

RandAugment 单独用：val Top-1 零变化

ΔB = -0.676

差异化 lr 单独用：val Top-1 掉 0.68 个点

I = +0.541

交互项为正，判定超加性（协同）

模型几乎不混淆猫狗，错误集中在品种之间

归一化混淆矩阵 37×37，行和 = 1.0，argmax 落在对角线 37/37 = 100%

猫狗块分析（关键结论）

3.56%

跨物种误判占比（10 / 281 个错误）

271 ↑

种内品种错误（96.4%）

猫 / 狗 召回

猫召回 88.17%

狗召回 94.33%

猫的召回明显低于狗：长毛猫品种间差异更小

最难的三类（按 F1 升序）

Staffordshire Bull Terrier

F1 0.691

American Pit Bull Terrier

F1 0.703

Ragdoll

F1 0.766

错误来自哪里

- ① 主体外观相似（多数）：斗牛梗类、长毛猫类的品种间差异本身就小
- ② 姿态/视角极端：侧躺、只露头部时判别性部位不可见
- ③ 背景干扰：主体占比小时注意力分散到背景

手写 Grad-CAM 定位到主体，外部实拍 8/8 判对

不依赖 pytorch-grad-cam，按 Selvaraju et al. ICCV 2017 公式 (1)(2) 自行实现

两个规范挂载点（不等价，已出对比图）

A（默认） `stages[-1].blocks[-1]`

残差相加后的激活，(B, C, 7, 7)

B（细粒度） `...channel_mixer.conv2`

残差相加前最后一个 1×1 卷积输出

绝不能挂 head / classifier：输出 2D，反传抛 Invalid grads shape

产出与观察

✓ 正确案例 6 张 · 错误案例 6 张

正确案例：热力图集中在头部与躯干轮廓

错误案例：同时点亮两类共有的特征区，
说明抓到的区域对，但判别力不足

约 6.2% 样本在背景上有明显响应 —— 数据集偏置

训练集以外的实际图片（跨集合实拍，ImageNet 同品种样本）

beagle	pug	boxer	chihuahua	samoyed	newfoundland	great_pyrenees	pomeranian
90.32%	43.86%	64.28%	67.98%	83.50%	77.14%	86.95%	36.91%

8/8 全部判断正确 —— 模型没有过拟合到 Pet 的拍摄风格

分布差异：外部图短边中位数 +10.5% · 亮度 +10.6% · 背景复杂度 +24%

来源声明：Wikimedia 不可达，改用 ImageNet 跨集合实拍图，逐张登记许可，不声称原创

重参数化在数值上完全等价，BN 节点归零

融合必须是代数恒等变换；必须在 eval() 之后做，否则 BN 用的是 batch 统计量

融合公式（手工推导并实测验证）

$$\text{BN}(y) = \gamma \cdot (y - \mu) / \sqrt{(\sigma^2 + \epsilon)} + \beta$$

$$y = W * x + b$$

$$W' = W \cdot \gamma / \sqrt{(\sigma^2 + \epsilon)}$$

$$b' = (b - \mu) \cdot \gamma / \sqrt{(\sigma^2 + \epsilon)} + \beta$$

1×1 核零填充成 3×3，identity 核中心为 1，三者逐元素相加

实测数值对照

max_abs_err 7.093e-06

mean_abs_err 2.031e-06

Top-1 是否一致 True (32/32)

BN 模块数 108 → 0

判定：max|Δ| < 1e-4 且 Top-1 恒等 → PASS

ONNX 计算图的变化

训练态图 nodes 480 · BN 24 · Conv 126 · 19.03 MB

推理态图 nodes 387 · BN 0 · Conv 103 · 18.89 MB

单 Block 融合（独立复刻验证）

C=384 3×3 核 [384,1,3,3] + 1×1 核 [384,1,1,1]

参数量 5760 → 3840 → 单个 3×3 depthwise

转换后仍存在的算子不是冗余

残留的 Add / Mul / Div / Clip / Relu 来自 GELU 激活、残差相加与逐样本归一化；SE 的 ReduceMean + 2×Conv 中间隔着非线性，本就无法折进一个卷积

6 个 ONNX 模型, PyTorch↔ONNX Top-1 一致率 100%

文件名一律经 `deploy/model_registry.py` 的 `onnx_path(key)` 取得, 任何地方不硬写

registry key	大小 (MB)	图内节点	类别数 / 标签
<code>repvit_m0_9_in1k</code>	20.36	BN=0 Conv=103	1000 / imagenet
<code>repvit_m1_0_in1k</code>	27.33	BN=0 Conv=103	1000 / imagenet
<code>repvit_m1_1_in1k</code>	33.06	BN=0 Conv=95	1000 / imagenet
<code>repvit_m1_5_in1k</code>	56.35	BN=0 Conv=167	1000 / imagenet
<code>repvit_m2_3_in1k</code>	91.90	BN=0 Conv=215	1000 / imagenet
<code>repvit_m0_9_pet37</code>	18.89	BN=0 Conv=103	37 / pet

独立实现

部署侧用 PIL 手写
`resize + crop + normalize`
不 import torchvision

为什么必须独立

共用一份 transform 会让一致性
误差恒为 0, 反而掩盖预处理
bug

标签绝不混用

1000 类 → imagenet
37 类 → pet

registry 的 `labels_for(key)`
按模型强制选择, 行数 $\neq$
`num_classes` 立即断言失败

PyTorch 与 ONNX 一致性 (固定划分列表、真实图片)

最大 logits 绝对误差	6.199e-06	3 个模型全部 PASS, 没有 出现题目列出的九类典型 问题 (Resize 顺序 / RGB- BGR / 插值 / mean-std / eval 模式)
平均 logits 绝对误差	1.501e-06	
Top-1 一致率 (推荐 ≥ 0.99)	100.00%	
Top-5 集合一致率	100.00%	

延迟不与 MACs 成正比，M1.1 是零增益的被支配点

ORT 1.30.0 CPUExecutionProvider · FP32 · batch=1 · 224×224 · 预热 10 + 正式 50 · threads=4

模型	mean	P50	P95	Top-1	边际收益 (acc / ms)
m0_9_in1k	7.45	7.37	8.00	78.20%	M0.9 → M1.0 +0.96
m1_0_in1k	9.20	9.15	9.76	79.90%	M1.0 → M1.1 0.00
m1_1_in1k	10.41	10.23	11.24	79.90%	M1.1 → M1.5 +0.39
m1_5_in1k	17.78	17.65	18.93	82.80%	M1.5 → M2.3 +0.02
m2_3_in1k	32.65	32.69	33.32	83.10%	
m0_9_pet37	7.20	7.12	7.69	92.34%	推荐 (P50 ≤ 15 ms 预算) repvit_m0_9_in1k

为什么更大的模型不一定按 MACs 比例变慢

- ① 小模型受固定开销支配（算子启动、内存分配、线程同步与计算量同量级）
- ② depthwise 卷积算术强度低，瓶颈在内存带宽而非算力
- ③ 分类头维度差异被放大：37 类的 Gemm 比 1000 类小得多

mean 易被慢样本拉高；P50 是典型耗时，最适合横向比较；P95 反映尾延迟（本机 P95/P50 ≈ 1.09，分布很稳）
不同设备 / 后端 / 精度下的延迟不可横向比较；官方 iPhone 12 延迟不得与本机 CPU 结果直接对比

复现链路完整、数字可溯源、控制变量有工程化校验

37 条验收项自检 0 失败；代码零写死绝对路径；每个数字都能回到 outputs/ 里的文件

三个最有代表性的问题

- 01 官方 .pth 与 timm 键名交集为 0 (713 vs 389)
实测证明两条路线权重逐位等价 ($\max|\Delta\text{logits}| = 0$)，省去手写键转换器
- 02 data/provided/ 在 29 页试题 PDF 中从未定义
改判为结构性偏差，改用官方归档 + 自建子集，并在 README 与报告中显式声明

- 03 早停导致训练预算不等价 (opt_mix 25 epoch vs baseline 40 epoch, 差 37.5%)
处置：统一关闭早停，8 组实验全部 40 epoch 满预算；把预算等价性固化成可执行检查 same_budget.py

结论

- ① RepViT 确为纯卷积，M0.9 实测 78.20%，贴近官方 78.7%
- ② Pet-37 test Top-1 92.34%，跨物种错误仅 3.56%
- ③ 重参数化数值等价、BN 归零；ONNX 一致率 100%
- ④ 四项优化均未超出噪声：这本身是有价值的负面结论

后续计划

INT8 量化 / 知识蒸馏 (M2.3 $\rightarrow$ M0.9)
集显后端 (本机无集显，需换设备)
置信度校准 (实测温度 $T = 0.615$)
七类鲁棒性扰动已跑，可扩展 severity 级