

REPVIT REPRODUCTION

RepViT 轻量图像分类模型 复现、优化与多模型部署

2026 秋 one 团队 AI 算法组考核 · 答辩汇报

RepViT: Revisiting Mobile CNN From ViT Perspective · CVPR 2024 · arXiv:2307.09283

github.com/8ga-tech/RepViT-Reproduction



68.70%

ImageNetV2 固定子集 Top-1

92.34%

Pet-37 test Top-1

7.093e-06

结构重参数化 (32 随机输入) $\max|\Delta|$

100%

ONNX 一致 (入库 5 型号各 12 张)

口径分开: 结构重参数化 = 32 个固定随机输入 ($\max|\Delta|$ 7.093e-06, Top-1 32/32); ONNX 一致性 = 入库的 5 个型号 (M0.9-Pet37 / M0.9 / M1.0 / M1.1 / M1.5) 各 12 张真实图片 (第 13 页, 5 份 n=12 落盘), 只覆盖这些图片, 不代表全部六个 ONNX 型号 (M2.3 未入库)。旧的 5.25e-06 未找到配套产物。

六个考核环节全部交付，34 条验收项自检 0 失败

运行 → 迁移 → 优化 → 可视化 → 重参数化 → 部署，每个数字都可在仓库中溯源

01

官方模型评价

5 个型号 · ImageNetV2 1000 张

M0.9 Top-1 68.70%

outputs/pretrained_eval/

02

M0.9 迁移训练

Pet 37 类 · 40 epoch

test Top-1 92.34%

checkpoints/baseline_best.pt

03

控制变量优化

4 方案 + 3 组消融

7 份配置 DIFF PASS

configs/opt_*.yaml

04

可视化与可解释性

五条曲线 · 混淆矩阵 · Grad-CAM

跨物种错误仅 3.56%

outputs/gradcam/

05

结构重参数化

BN 107 → 0 · Conv 126 → 103

$\max|\Delta|$ 7.093e-06 · 32/32 一致

outputs/reparam/

06

ONNX 多模型部署

6 个 ONNX · ORT CPU

P50 7.68 ~ 34.41 ms

onnx/*.onnx

范围声明：不做第八章拓展任务（INT8 量化 / 知识蒸馏 / 剪枝 / 多随机种子 / 边缘部署 / 核心模块独立实现）

02

口径与边界：PyTorch 与 ONNX 的 Top-1 一致率只测了入库的 5 个型号（M0.9-Pet37 / M0.9 / M1.0 / M1.1 / M1.5）各 12 张（均为 100%）；其余型号（M2.3 未入库）只有导出检查与性能结果，不做同口径一致性声明。重参数化 7.093e-06 来自 32 个固定随机输入，与上面这批 ONNX 实验不是同一批。

M0.9 是纯卷积流水线：名字里有 ViT，结构里没有注意力算子

环节 2 + 环节 3 合并页 · 左：M0.9 结构（形状由 forward hook 现测）；右：标准 ViT 与 RepViT 逐项对应

左栏 · 环节 2：M0.9 是一条纯卷积流水线

输入 224×224×3 RGB
Stem conv1 3×3 s2 → 24ch 112×112; conv2 3×3 s2 → 48ch 56×56
Stage 0 2 × RepViT Block 48ch 56×56
Stage 1 2 × RepViT Block 96ch 28×28
Stage 2 14 × RepViT Block 192ch 14×14 (Block 最多)
Stage 3 2 × RepViT Block 384ch 7×7
GAP → 384 维 Head RepVitClassifier (NormLinear) → 37 维

单个 RepViT Block 内部

空间混合 (Token Mixer) : RepVGGDW = 3×3 dw + 1×1 dw
通道混合 (Channel Mixer) : 1×1 升维 → GELU → 1×1 降维
残差连接; SE 只放在部分 Block (全局池化有真实延迟)
训练态: 3×3 dw 分支 + 1×1 dw 分支, 各自带 BatchNorm
推理态: BN 折进卷积核后相加 → 单个 3×3 depthwise 卷积
整条链路只有卷积 / GELU / 池化, 没有注意力; 名字里的 ViT 说的是宏观架构选择。

右栏 · 环节 3：标准 ViT 与 RepViT 的对应关系

环节	标准 ViT	RepViT
空间混合	Multi-Head Self-Attention	RepVGGDW (3×3 dw + 1×1 dw)
通道混合	MLP / FFN	Channel Mixer (1×1→GELU)
下采样	patchify (stride=16 大核)	Early Conv Stem (两组 stride=2)
归纳偏置	弱, 依赖大数据	强 (卷积自带局部性 / 平移等变)
ONNX 图内	MatMul + Softmax	无注意力算子

实证: onnx/*.onnx 的算子直方图里只有 Conv / Gemm / Add / Mul / Div / Clip / Relu , 没有 MatMul + Softmax 这一对注意力算子组合 (outputs/reparam/repvit_m0_9_onnx_nodes.json) 。

四个关键设计

- ① 分离 Token / Channel Mixer —— 空间与通道容量可独立调节
- ② 扩张比降到约 2 并同时加宽 —— 省下的 MACs 换成通道数
- ③ SE 不做每块都放 —— 全局池化的延迟不可忽略
- ④ 简单分类头 —— 单个 BN + Linear, 省真实延迟

M0.9 实测: 20 个 Block, 按 Stage 分布 [2, 2, 14, 2]

官方权重在 ImageNetV2 固定子集上的实际表现

5 个官方型号 · ImageNetV2 matched-frequency 固定子集 1000 张 (1000 类各 1 张, 确定性选取) · 224×224 · batch 64 · FP32 · NVIDIA GeForce RTX 4060 Laptop GPU

型号	参数量 (M)	MACs (G)	文件大小 (MB)	Top-1	Top-5
M0.9	5.067	0.847	21.38	68.70%	85.70%
M1.0	6.810	1.143	28.30	69.20%	86.40%
M1.1	8.244	1.377	34.02	70.80%	87.20%
M1.5	14.050	2.340	56.62	71.40%	89.00%
M2.3	22.927	4.626	91.42	73.60%	89.90%

预处理口径必须标

crop_pct = 0.875 → Resize(256) + CenterCrop(224)
crop_pct = 0.95 → Resize(235) + CenterCrop(224)
M0.9: 68.70 / 68.30
M1.0: 69.20 / 69.40
两套口径差 0.2~1.9 个点

必须声明的口径边界

- ImageNetV2 是独立重采样的测试集，不代表论文完整 ImageNet-1K 验证集结果；本页 Top-1/Top-5 与论文/官方的 ImageNet-1K 公布值不可直接比较。
- 清单固定可复现：1000 类各 1 张、按类目录内文件名 sorted() 取第一个、无随机种子 (datasets/lists/imagenetv2_mf_1000.txt) 。
- 参数量取「融合后单头」口径；MACs 取 thop「未融合」口径 (不乘 2) ；官方 iPhone 12 延迟 (0.9 / 1.0 ms) 与本机结果不可横向比较，延迟口径见第 14 页。

两套数据两套标签，三层划分零泄漏

37 类与 1000 类必须分别使用各自的标签文件；混用会让 Top-5 名称整体错乱

Oxford-IIIT Pet 划分（唯一划分脚本，seed=42）

trainval.txt
3680 行

pet_train.txt
2940 行 · 每类 73~80

pet_val.txt
740 行 · 每类恰好 20

test.txt
3669 行

pet_test.txt
3669 行 · 每类 88~100

Baseline 的 test 只评价 1 次
eval_count = 1

官方 CLASS-ID 是 1-based, 0-based 标签 = CLASS-ID - 1；类名用 rsplit('_', 1) 取前缀

泄漏检查（三层 + 内容级）

文件名交集 0 / 0 / 0

MD5 交集（防改名） 0 / 0 / 0

孤儿图误入 0

划分内部重复图 0

python datasets/audit_leakage.py

官方数据事实基线（全部实测）

7390

images/ 下的 jpg

3680

trainval.txt 行数

3669

test.txt 行数

12 / 25

猫 / 狗 类别数

1-based

官方 CLASS-ID

官方不存在 train.txt / val.txt，只有 trainval.txt 与 test.txt；train/val 必须自行分层切分

40 epoch 迁移训练把 test Top-1 做到 92.34%

AdamW · cosine + 3ep warmup · Label Smoothing 0.1 · bf16 autocast · batch 64 · seed 42

测试集 (3669 张, 只评价一次)

92.34%

Top-1 Accuracy

99.26%

Top-5 Accuracy

92.22%

Macro-F1

验证集 (740 张) best 选模依据 val_macro_f1 = 0.9462 @ epoch 34

训练检查

- ✓ 骨干确实被训练 706 张量
- ✓ 其中骨干张量 699 个
- ✓ Baseline 的 test 只评价 1 次 eval_count=1
- ✓ 权重加载无异常 unexpected=0

1000 类 → 37 类: 怎么做、差异在哪

正确做法

```
timm.create_model(..., num_classes=37,  
distillation=False)
```

保留分类头的 BN 统计量 (与类别数无关的迁移先验)
missing = 2 (仅换头后的 Linear weight / bias)

禁止做法

```
model.reset_classifier(37)
```

会丢掉 head.head.bn 的统计量; distillation=False 时
head_dist 属性被整体删除, 后续断言必然失败

四组优化各有假设，控制变量由工具强制校验

Baseline 有两个问题：样本仅 2940 张而参数 473 万（过拟合风险）；主干前期被大学习率推离预训练解

B 混合增强

3 个差异键

Mixup $\alpha=0.2$ + CutMix $\alpha=1.0$ ，每个 batch 都做

假设：混合两张图片与标签，尝试减少对训练样本的记忆

代价：需要更多 epoch 才能收敛

C 加强数据增强

8 个差异键

RandAugment($n=2$, $m=9$) + RRC scale 下限 $0.35 \rightarrow 0.25$

假设：覆盖旋转 / 剪切 / 色调变换，减少对局部纹理的依赖

风险：2940 张下容易过增强

D 差异化学习率

1 个差异键

主干倍率 $0.1 \rightarrow 0.05$ （有效 lr $1e-4 \rightarrow 5e-5$ ）

假设：新头快速收敛，让主干更新幅度更小

代价：训练曲线整体右移

A 组合式（基础任务所选项）

12 个差异键

B + C + D 全开

假设：三者机制互补，前段更稳 + 末段更高

风险：正则叠加会延长收敛

控制变量不是靠自觉，而是可执行校验

```
python tools/diff_config.py configs/baseline.yaml configs/opt_combo.yaml
```

叶子级比对，实际差异键必须与配置声明的 `_expected_diff_` 逐项一致

7 份配置全部 DIFF PASS (3 / 8 / 1 / 12 / 8 / 1 / 9 键)

```
python tools/same_budget.py → total_iters_equal=True (8 组均为 40 epoch × 45 step)
```

保持不变


数据划分 · 预训练权重 · 种子

训练预算 · 评价方式 · 选模标准


训练曲线：两组都收敛，组合方案未提高测试准确率

RepViT-M0.9 · Pet-37 · 输入 224×224 · batch 64 · NVIDIA GeForce RTX 4060 Laptop GPU · PyTorch 2.14.0+cu126 (bf16 autocast) · 曲线共用坐标范围 · test 评价次数 Baseline 1 / 组合 2


训练损失




验证损失




验证 Top-1 (%)



验证 Macro-F1 (%)



学习率





测试集结果 (3669 张)

指标	Baseline	组合
Top-1	92.34%	92.12%
Top-5	99.26%	99.59%
Macro-F1	92.22%	92.01%



前几轮提升最快，后段逐渐稳定。
软标签改变 train loss，不能直接横比。
单种子结果不足以判断稳定提升。

错在哪里：多数是同物种内的品种混淆

Baseline · Pet-37 test · 3669 张 · PyTorch 2.14.0+cu126 / CUDA / FP32 / 224×224 / 每张只推理一次 · 左：行归一化混淆矩阵；中：每类 F1 柱状图；右：失败案例



281 个错误中，10 个跨猫狗物种 (3.56%)
，其余 271 个是同物种品种判断错误。



上面两张是失败案例：相似外形、遮挡和背景都会影响判断；热力图只能用来检查线索，不能仅凭它确定因果。

每类 F1：最低 0.696 (Staffordshire Bull Terrier)
，最高 0.995 (Japanese Chin)；37 类 Macro-F1 = 92.22% (数据源 baseline_per_class.csv)。

下一步：补充容易混淆的品种（上面这类）和不同拍摄角度

Grad-CAM: 同时看判对和判错的图片

Baseline · 挂载 stages[-1].blocks[-1] · 原图 / 热力图 / 叠加图 · PyTorch 2.14.0+cu126 / CUDA / FP32 / 224×224 / 每张只推理一次


正确: Bengal



正确: Russian Blue



失败: Boxer



失败: Egyptian Mau




关注到主体 $\neq$ 品种一定判断正确。热力图用于检查线索，仍要结合失败案例和完整测试集（3669 张）。

预测结果：8 张测试集 + 4 组同图对比 + 5 张实拍

Baseline = RepViT-M0.9 Pet-37 (test Top-1 92.34%) · 逐张 Top-5 类别与置信度 · 每个面板下方标注该面板自己的推理口径

① 同图对比 4 组

Baseline vs 组合方案




按 image_id 配对 (不按行号)；全测试集里两模型预测不同的有 142 张。

落盘 JSON 另抽的 4 张两组都判对 (both_correct=4、fixed_by_opt=0、broken_by_opt=0) ——同图对比要看有差异的样本。

口径：PyTorch / CUDA / FP32 / 224×224 / eval batch 128 / 每张只推理一次。

来源：outputs/predictions/{baseline_test_preds,cases_test_baseline}.csv · baseline_vs_opt_combo_predict_compare.json · outputs/benchmarks/external_top5_repvit_m0_9_pet37.csv · distribution_compare_summary.csv


② 测试集预测 8 张 (Top-5 类别 + 置信度)



取测试列表顺序前 8 张 (Abyssinian_2 ... Abyssinian_207)：8/8 判对，Top-1 置信度 0.508 ~ 0.900；顺序取样，不是挑出来的好例子。

口径：PyTorch / CUDA / FP32 / 224×224 / eval batch 128 / 每张只推理一次。

③ 训练集以外的实拍图片 5 张 (Top-5 类别 + 置信度)



Top-1 置信度 (图从左到右)：Beagle 0.903、Boxer 0.643、Chihuahua 0.680、Great Pyrenees 0.869、Newfoundland 0.771 —— 5 张都判到对应品种。

最低的 Boxer 只有 0.643：置信度低不等于判错，反过来高置信度也不保证一定可靠。

外部实拍共 8 张，本页展示按文件名排序的前 5 张 (试题要求 ≥ 5 张)；没有 GT (真值)，只看 Top-5 与置信度，不报准确率。


数据集 vs 外部图片的分布差异：短边均值 348 → 381 px，亮度均值 0.455 → 0.503，背景复杂度 0.478 → 0.593；分布不同，不能直接比准确率。

口径：ONNX Runtime 1.30.0 CPUExecutionProvider / FP32 / batch 1 / 224×224 / i7-13650HX / 每张只推理一次。

重参数化：合并分支后，误差仍在设定阈值内

RepViT-M0.9 Pet-37 (baseline_best.pt) · 1×3×224×224 · batch 8 · n=32 · i7-13650HX CPU · PyTorch 2.14.0+cu126 / FP32 · 1 次融合前后对比 · seed=20240912

PyTorch 模块数量



数值验证（32 个固定随机输入）	结果
最大 Δlogits	7.093e-06
平均 Δlogits	2.031e-06
Top-1 一致	32 / 32
Top-5 最小交集	5 / 5
阈值 / 判定	max < 1e-4 / PASS

做法：把 BN 的均值方差折进卷积核，再把 3×3、1×1 与 identity 三条分支的核相加，必须在 eval() 之后做。

看到：32 个固定随机输入 max|Δlogits| = 7.093e-06 (< 1e-4 阈值) ， Top-1 32/32 一致，BN 模块 107 → 0。

还不能说明：这是代数等价的替换 + 已测输入 + 设定阈值，不是位级完全相等，也不代表所有输入都如此。

PyTorch ↔ ONNX：固定 n=12，比较同一输入张量

原模型 vs 融合后 ONNX · ORT 1.30.0 CPUExecutionProvider · FP32 · batch 1 · 1×3×224×224 · i7-13650HX / Windows 11 · 入库的 5 个型号各 12 张真实图片 · 每张只跑一次

模型 / 输入列表	n	最大 Δlogits	平均 Δlogits	Top-1 / Top-5
M0.9 Pet-37 / pet_test	12	6.199e-06	1.501e-06	100% / 100%
M0.9 / ImageNetV2 子集	12	1.383e-05	2.334e-06	100% / 100%
M1.0 / ImageNetV2 子集	12	1.335e-05	2.215e-06	100% / 100%
M1.1 / ImageNetV2 子集	12	1.860e-05	2.219e-06	100% / 100%
M1.5 / ImageNetV2 子集	12	1.144e-05	1.876e-06	100% / 100%


- 1 重参数化 7.093e-06（32 个随机输入）是第 12 页的另一批实验，不与本页并成一句结论。
- 2 部署预处理由 PIL 独立实现；本次对比把同一张量送入两个推理后端，因此这里不比预处理实现。
- 3 结论仅覆盖每型号这 12 张图片：不能说成完整测试集，也不能说成全部六个模型一致。
- 4 旧的 5.25e-06 缺少对应完整记录，当前统一引用上表落盘值（4 位有效数字）。

复跑：python deploy/compare_torch_onnx.py --model repvit_m0_9_pet37 --limit 12
完整命令、固定列表与输出路径已写入本页备注和 report/LOGITS_AUDIT.md。


部署怎么选：先看同一机器上的延迟和准确率

型号：M0.9 / M0.9-Pet37 / M1.0 / M1.1 / M1.5 / M2.3 · 输入 $1 \times 3 \times 224 \times 224$ · batch 1 · i7-13650HX · ORT 1.30.0
CPUExecutionProvider · FP32 · 预热 10 + 正式 50 次 · threads 4

六个 ONNX 模型的推理耗时 (ms)



ImageNetV2 固定子集 (1000 张)：速度与准确率



右图只放 ImageNetV2 固定子集的五個官方型号，看的是「多花多少毫秒换多少点准确率」。更大模型的额外耗时，需要结合使用场景判断。

右图元信息：准确率来自 PyTorch 2.14.0+cu126 (64 batch / cuda / fp32) 在 ImageNetV2 固定子集 (同一 1000 张) 上的评价；延迟来自本机 ONNX Runtime CPU (batch 1)。两者口径不同，只做参考。

复现链路完整、数字可溯源、控制变量有工程化校验

34 条验收项目检 0 失败；代码零写死绝对路径；关键数字与实验口径见 outputs/ 和审计说明

三个最有代表性的问题

- 01 官方 .pth 与 timm 键名交集为 0 (713 vs 389)
实测两条路线权重逐位相同 (同进程同权重对比, $\max|\Delta \text{logits}| = 0$) , 省去手写键转换器
- 02 data/provided/ 在 29 页试题 PDF 中从未定义
改判为结构性偏差: 改用官方归档构建的 ImageNetV2 固定子集与 Oxford-IIIT Pet, 并在 README 与报告中显式声明
- 03 早停导致训练预算不等价 (opt_mix 25 epoch vs baseline 40 epoch, 差 37.5%)
处置: 统一关闭早停, 8 组实验全部 40 epoch 满预算; 把预算等价性固化成可执行检查 same_budget.py

结论

- ① RepViT 确为纯卷积; M0.9 在 ImageNetV2 固定子集上实测 68.70% (与 ImageNet-1K 公布值不可比)
- ② Pet-37 test Top-1 92.34% (跨物种错误仅 3.56%) ; 四项优化未显示稳定提升, 需多种子实验
- ③ 重参数化 (32 个固定随机输入) $\max|\Delta| = 7.093\text{e-}06$, Top-1 32/32 一致 (与下面 ONNX 实验分列)
- ④ ONNX 一致性 (Pet-37, n=12 真实图片) $\max|\Delta| = 6.199\text{e-}06$, Top-1/Top-5 集合一致率 100%

后续计划

INT8 量化 / 知识蒸馏 (M2.3 $\rightarrow$ M0.9)
集显后端 (本机无集显, 需换设备)
置信度校准 (实测温度 $T = 0.615$)
七类鲁棒性扰动已跑, 可扩展 severity 级